

CENTRO UNIVERSITÁRIO ESTÁCIO DE SÁ
CURSO DE GRADUAÇÃO TECNOLÓGICA CIÊNCIA DE DADOS

WANDERSON BALBINO FERREIRA VERTEIRO

TRABALHO DE AVALIAÇÃO FINAL
ANÁLISE EXPLORATÓRIA DE DADOS - E-COMMERCE OLIST

Belo Horizonte, MG

2025

WANDERSON BALBINO FERREIRA VERTEIRO

ANÁLISE EXPLORATÓRIA DE DADOS - E-COMMERCE OLIST

Trabalho de conclusão de semestre no curso
Ciência de Dados, referente a disciplina
Preparação de Dados na Universidade
Estácio de Sá.

Orientador: Prof. Bruno Martins Bartolomeu

Belo Horizonte

2025

SUMÁRIO

RESUMO.....	4
ABSTRACT.....	5
MAPEAMENTO SEGUNDO A METODOLOGIA CRISP-DM.....	6
FASE 1: COMPREENSÃO DO NEGÓCIO.....	6
FASE 2: COMPREENSÃO DOS DADOS.....	6
FASE 3: PREPARAÇÃO DOS DADOS.....	7
FASE 4: AVALIAÇÃO.....	7
PONTOS FORTES DA ANÁLISE.....	11
RECOMENDAÇÕES ESTRATÉGICAS.....	11
1) Expansão Geográfica do Marketplace.....	11
Recomendações:.....	11
KPI sugeridos:.....	12
2) Otimização de Categorias e Competitividade.....	12
Recomendações:.....	12
KPI sugeridos:.....	12
3) Melhoria da Atração e Retenção de Vendedores.....	12
Recomendações:.....	13
KPI sugeridos:.....	13
4) Governança e Qualidade dos Dados.....	13
Recomendações:.....	13
KPI sugeridos:.....	13
CONCLUSÕES.....	14
REFERÊNCIAS.....	16

RESUMO

O objetivo do presente trabalho é realizar uma análise exploratória de dados (EDA) do e-commerce Olist para identificar padrões de distribuição geográfica, portfólio de produtos e performance logística, fornecendo insights estratégicos para a gestão. Utiliza-se a metodologia Cross-Industry Standard Process for Data Mining (CRISP-DM) como estrutura de análise, empregando o software Python e as bibliotecas Pandas, Seaborn e Matplotlib para processamento e visualização dos dados. O método consistiu na integração de múltiplos datasets da Olist, seguida pela análise da contagem de vendedores por estado, a identificação das dez categorias de produtos mais vendidas e o cálculo da diferença entre o tempo real e o tempo estimado de entrega. Os resultados demonstram uma forte concentração de vendedores na região Sudeste do Brasil, o que justifica a recomendação de expansão geográfica para mitigar riscos de dependência regional. Adicionalmente, identifica-se que as categorias de Cama, Mesa e Banho, Beleza e Saúde e Esporte e Lazer lideram o volume de vendas. No aspecto logístico, constata-se uma alta eficiência operacional, com uma média de antecipação de entrega de 11.28 dias em relação ao prazo prometido, configurando-se como um diferencial competitivo. Em conclusão, o trabalho valida a necessidade de uma estratégia de crescimento geográfico e de otimização do portfólio, ao mesmo tempo que revela a performance logística como um ponto forte a ser capitalizado, sugerindo-se a correção da interpretação inicial para que o relatório reflita esta vantagem competitiva.

Palavras-chave: Análise Exploratória de Dados, Olist, CRISP-DM, Logística, E-commerce.

ABSTRACT

This work aims to conduct an Exploratory Data Analysis (EDA) of the Olist e-commerce platform to identify patterns in geographical distribution, product portfolio, and logistics performance, providing strategic insights for management. The Cross-Industry Standard Process for Data Mining (CRISP-DM) methodology is used as the analytical framework, employing Python software and the Pandas, Seaborn, and Matplotlib libraries for data processing and visualization. The method consisted of integrating multiple Olist datasets, followed by analyzing the count of sellers by state, identifying the top ten best-selling product categories, and calculating the difference between the actual and estimated delivery times. The results demonstrate a strong concentration of sellers in the Southeast region of Brazil, which justifies the recommendation for geographical expansion to mitigate regional dependency risks. Additionally, it is identified that the categories of Bed, Bath & Table, Health & Beauty, and Sports & Leisure lead the sales volume. Regarding logistics, it is found that there is exceptionally high operational efficiency, with an average delivery anticipation of 11.28 days compared to the promised deadline, establishing itself as a competitive differential. In conclusion, the work validates the need for a geographical growth strategy and portfolio optimization, while also revealing logistics performance as a key strength to be capitalized upon, suggesting the correction of the initial interpretation so that the report reflects this competitive advantage.

Keywords: Exploratory Data Analysis, Olist, CRISP-DM, Logistics, E-commerce.

MAPEAMENTO SEGUNDO A METODOLOGIA CRISP-DM

Foram realizadas análises exploratórias de dados (EDA) seguindo todas as fases da metodologia CRISP-DM. O dataset utilizado foi cedido pela Olist, um conjunto de dados público de e-commerce brasileiro disponibilizado no Kaggle, sob a licença CC BY-NC-SA 4.0.

O conjunto de dados utilizados contém mais de 100 mil pedidos realizados entre os anos de 2016 a 2018 de diversas empresas de marketplaces brasileiras no qual pode ser apreciado no link: <https://github.com/wandbalbino/EcommerceOlist>

FASE 1: COMPREENSÃO DO NEGÓCIO

A escolha do dataset Olist, direcionando a estrutura da análise seguiu para três etapas principais:

- Distribuição geográfica
- Categorias mais vendidas
- Performance logística

FASE 2: COMPREENSÃO DOS DADOS

A análise utilizou o dataset *vendedores_geo*, que reúne informações geográficas dos vendedores. Inicialmente, foi realizada a contabilização do número de vendedores por estado, a partir da coluna *seller_state*.

Em seguida, o mesmo dataset foi utilizado para examinar a coluna *product_category_name_english*, na qual as categorias foram contabilizadas, ordenadas conforme a quantidade de produtos vendidos ou registrados e, posteriormente, selecionadas as dez categorias com maior volume.

2.1 Carregamento e Exploração Inicial

- Montagem dos arquivos para acesso aos dados;
- Carregamento de múltiplos datasets em um dicionário de DataFrames;
- Visualização das dimensões (linhas × colunas) de cada dataset;
- Exibição das primeiras linhas para inspeção visual

- Utilização das bibliotecas Pandas, Seaborn, Matplotlib.pyplot e Squarify

2.2 Ordenação e seleção dos Top 10

- Os estados foram ordenados de forma decrescente.
- Apenas os 10 maiores estados em volume de vendedores.

Visualização

Nesta etapa do trabalho de análise, foi construído um gráfico de barras horizontais em ordem decrescente, facilitando a comparação entre os estados com as bibliotecas utilizadas: **Seaborn + Matplotlib**.

FASE 3: PREPARAÇÃO DOS DADOS

Embora não haja transformações complexas, algumas preparações foram realizadas após o tratamento de duplicatas removendo duplicatas de CEP no dataset de geolocalização, mantendo apenas um registro por prefixo de CEP.

O trabalho de modelagem neste projeto não seria aplicável, pois o código se concentra exclusivamente em análise exploratória, sem construção de modelos preditivos ou de machine learning.

FASE 4: AVALIAÇÃO

A avaliação dos dados permite identificar tres aspectos centrais do desempenho operacional e comercial. Observa-se que os vendedores encontram-se majoritariamente nos 10 maiores estados, destacando para os da região Sudeste.

Esta concentração sugere uma capacidade de infraestrutura, logística com grande diferencial das demais localidades, refletindo padrões tradicionais na distribuição econômica do Brasil

Referente ao portfólio, verifica-se algumas categorias com grande destaque significativo nas vendas, com ênfase sports leisure, stationery e diversos itens de eletrodomésticos. Essas categorias têm notoriedade tanto pelo volume de produtos

cadastrados quanto pelas vendas, evidenciando maior demanda pelo consumidor e acentuando presença dos vendedores especializados nesses segmentos.

Por fim, em relação ao tempo estimado e ao tempo real de entrega, a análise identificou um desempenho logístico excepcionalmente eficiente. A média do tempo real de entrega é significativamente inferior ao prazo originalmente estimado, resultando em uma antecipação média de 11.28 dias para o cliente. Este resultado demonstra uma robusta capacidade operacional e uma previsão de prazo conservadora, o que se configura como um forte diferencial competitivo para a Olist.

No entanto, a análise do desvio-padrão e da distribuição dos dados indica que, apesar da excelente média, uma pequena parcela de pedidos ainda pode sofrer atrasos pontuais. Esta observação reforça a necessidade de aprimorar a acurácia das estimativas para os casos de exceção e mitigar os riscos de falhas isoladas.

Top 10 Categorias

Referente ao portfólio, verifica-se algumas categorias com grande destaque significativo nas vendas, com ênfase em sports leisure, stationery e diversos itens de eletrodomésticos. Essas categorias têm notoriedade tanto pelo volume de produtos cadastrados quanto pelas vendas, evidenciando maior demanda pelo consumidor e acentuando a presença dos vendedores especializados nesses segmentos.

A análise detalhada das categorias mais vendidas revela que o Top 10 é composto por Cama, Mesa e Banho, Beleza e Saúde, Esporte e Lazer, Informática e Acessórios, Casa e Construção, Telefonia, Eletrodomésticos, Moda Acessórios, Bebê e Papelaria.


Em um insight separado, a distribuição geográfica dos vendedores demonstra que os estados de São Paulo, Minas Gerais, Paraná, Rio Grande do Sul, Rio de Janeiro, Santa Catarina, Bahia, Goiás, Distrito Federal e Espírito Santo concentram a maior parte da base de sellers da plataforma.

Avaliação dos Gráficos Utilizados

Foram criadas para analisar a distribuição geográfica dos vendedores em ordem decrescente no qual o foco é identificar os estados com maior concentração de vendedores para detectar possíveis desequilíbrios regionais na plataforma e compreender a cobertura geográfica do marketplace apresentado em:


1) Gráfico de barras horizontais (barplot)

- a) Detalhamento das top 10 vendedores com maior percentual de vendas
- b) Ordenado por frequência decrescente (do maior para o menor)
- c) Evidencia as diferenças claras de volume entre os estados




2) Gráfico Categorias Mais Vendidas

- a) Domínio de categorias utilitárias e essenciais
- b) Participação das categorias de tecnologia
- c) Diversificação do perfil de consumo



3) Distribuição de Entrega (Real – Estimado)

- a) Interpretação da Média
- b) Interpretação do Gráfico de Distribuição
- c) Padrão Geral Observado



PONTOS FORTES DA ANÁLISE

A análise demonstra integração de múltiplas fontes de dados com compreensão das relações entre tabelas, uso de visualizações diversificadas para comunicar insights, foco geográfico por meio de análise espacial, aplicação de técnicas básicas de qualidade de dados como remoção de duplicatas e organização modular utilizando dicionários para gerenciar múltiplos DataFrames.

Os 10 maiores estados demonstram que o Olist possui forte presença em regiões consideradas economicamente, com enorme potencial de crescimento em estados emergentes.

RECOMENDAÇÕES ESTRATÉGICAS

A distribuição de vendedores está fortemente concentrada em poucos estados (SP, RJ, MG), enquanto as regiões Norte e Centro-Oeste têm baixa representatividade — *dependência excessiva = risco estratégico*.

1) Expansão Geográfica do Marketplace

Reduzir concentração regional de vendedores, aumentar cobertura nacional e melhorar resiliência operacional com base na análise realizada há uma percepção que a distribuição de vendedores está fortemente concentrada em poucos estados (SP, RJ, MG), enquanto regiões Norte e Centro-Oeste têm baixa representatividade — *dependência excessiva = risco estratégico*.

Recomendações:

- Criar programas de expansão regional, com incentivos financeiros para novos vendedores em estados sub-representados, parcerias com associações empresariais regionais e campanhas segmentadas por faixa de CEP
- Estratégia “Regional Growth Targets” (Metas de crescimento regional) no qual estabelece metas trimestrais por região para aumentar a base de sellers.
- Análise logística complementar, no qual identifica gargalos de entrega e lead time nas regiões de baixa penetração.

KPI sugeridos:

- Crescimento percentual de vendedores por estado
- Diversidade geográfica (índice Herfindahl-Hirschman)
- SLA logístico médio por região

2) Otimização de Categorias e Competitividade

Melhorar o equilíbrio competitivo entre categorias e aumentar receita por categoria. Categorias como *beleza, eletrônicos e utilidades domésticas* concentram grande volume de vendedores → alta competição. Outras categorias apresentam potencial não explorado.

Recomendações:

- Reposicionar incentivos por categoria, com taxas reduzidas para nichos estratégicos e campanhas específicas para categorias emergentes
- Identificar espaços de mercado (blue oceans), com base nos dados, sugerir expansão em categorias pouco competitivas, mas com demanda crescente.
- Benchmarking interno e comparar categorias com maior crescimento de receita por vendedor.

KPI sugeridos:

- Receita por categoria
- Crescimento de sellers por categoria
- Nível de competitividade (sellers por categoria / vendas)

3) Melhoria da Atração e Retenção de Vendedores

Aumentar a qualidade e longevidade dos vendedores na plataforma, identificar forte concentração em regiões metropolitanas (possível insuficiência de penetração de mercado).

Recomendações:

- Programa de Onboarding Inteligente com tutoriais segmentados por região/categoria e suporte personalizado para novos vendedores.
- Diagnóstico de performance geográfica, realizando mapeamentos onde vendedores abandonam ou apresentam baixo desempenho.
- Incentivos baseados em jornada, oferecendo benefícios conforme o tempo de operação e qualidade.

KPI sugeridos:

- Taxa de churn de vendedores
- Tempo médio até primeira venda
- Lifetime value (LTV) de vendedores

4) Governança e Qualidade dos Dados

Elevar maturidade analítica e garantir confiabilidade das bases de dados, as quais foram necessários ajustes básicos (duplicatas, padronização) — indicando desafios estruturais.

Recomendações:

- Criar pipeline de qualidade de dados com regras automáticas de validação (CEP, IDs, coordenadas), sistema de monitoramento (Data Quality Score).
- Padronizar nomenclatura e chaves e promover consistência no uso de IDs e colunas comuns.
- Treinamento interno em boas práticas para que ocorra capacitação dos times internos para evitar erros recorrentes.

KPI sugeridos:

- Percentual de dados válidos
- Ocorrência de duplicatas
- Taxa de falhas de integração

CONCLUSÕES

O relatório de Análise Exploratória de Dados (EDA) da Olist, seu objetivo é validar a análise e garantir que as decisões estratégicas sejam tomadas com base em dados precisos.

As análises de Distribuição Geográfica de Vendedores e de Categorias de Produtos estão validadas. Elas confirmam a alta concentração na base de vendedores na região Sudeste, o que justifica plenamente a recomendação estratégica de Expansão Geográfica para mitigar riscos de dependência regional e buscar novos mercados. Da mesma forma, a análise de categorias fornece a base para a Otimização do Portfólio e a gestão da competitividade.

Identificamos uma inconsistência crítica na interpretação da análise de logística que, se corrigida, transforma um suposto problema em um diferencial competitivo de mercado.

O relatório conclui que há um gargalo logístico, com o tempo de entrega real superando o estimado. No entanto, os dados consolidados demonstram o oposto:

Métrica	Valor (Dias)
Média do Tempo Real de Entrega	12.09
Média do Tempo Estimado de Entrega	23.37
Média de Antecipação (Atraso)	-11.28

Para garantir a máxima credibilidade e impacto do relatório, sugerimos as seguintes ações:

- Correção Estratégica da Logística:** O relatório deve ser reescrito para destacar a antecipação média de entrega como um case de sucesso operacional. Devemos, então, focar a análise de risco na pequena parcela de pedidos que ainda atrasa, identificando os gargalos pontuais para eliminá-los.

2. **Alinhamento de Dados:** É necessário revisar a tabela de categorias no relatório para que ela reflita exatamente os dados gerados pelo código. A precisão dos dados apresentados é inegociável para a confiança da gestão.
3. **Governança de Dados:** O relatório já sugere a melhoria da Governança e Qualidade dos Dados, o que é crucial. Sugerimos que o código seja revisado para eliminar warnings técnicos, garantindo que a base de dados seja robusta e livre de erros que possam comprometer análises futuras.

REFERÊNCIAS

Olist, and André Sionek. (2018). Brazilian E-Commerce Public Dataset by Olist [Data set]. Kaggle. <https://doi.org/10.34740/KAGGLE/DSV/195341>. Acesso em: 2025-10-20

DE DADOS, Introdução à. Mineração. Entenda as principais metodologias de mineração de dados: CRISP-DM, SEMMA e KDD. Introdução à Mineração de Dados, 13 abr. 2023. Disponível em: <https://www.dataimd.com/post/entenda-as-principais-metodologias-de-minera-o-de-dados-crisp-dm-semma-e-kdd/>. Acesso em: 2025-10-20

DATA SCIENCE PM. What Is CRISP DM? Disponível em: <https://datascience-pm.com/crisp-dm-2>. Acesso em: 2025-10-20

MATPLOTLIB. Matplotlib: Python Plotting — Matplotlib 3.1.1 Documentation. Disponível em: <https://matplotlib.org>. Acesso em: 2025-10-25

PANDAS. Python Data Analysis Library. Disponível em: <https://pandas.pydata.org>. Acesso em: 2025-10-25

SEABORN. seaborn: statistical data visualization — seaborn 0.9.0 documentation. Disponível em: <https://seaborn.pydata.org>. Acesso em: 2025-10-25

Squarify. Disponível em: <https://pypi.org/project/squarify/>. Acesso em: 2025-11-24